

확률과 통계

섹션 - 6

강사 : James 쌤



유료 강의자료입니다. 지은이의 허락없이 무단 복제와 배포를 엄격히 금합니다.

로지스틱회귀 원리

키포인트


- 로지스틱 회귀의 원리.
- 로지스틱 회귀를 적용한 학습과 예측.

지도학습 머신러닝

지도학습의 세분화


수치형 Y

$Y = 13.45, 73, 9.5, \dots$



명목형 Y

$Y = \text{red}, \text{green}, \dots$



지도학습 머신러닝

지도학습의 평가

```
graph TD; A[지도학습의 평가] --> B[수치형 Y]; A --> C[명목형 Y];
```

수치형 Y

MSE, MAE, RMSE,
Correlation, 등.

명목형 Y

Confusion Matrix, Accuracy,
Precision, Recall, Specificity, 등.

로지스틱회귀 개요

- 로지스틱 회귀는 **이진 분류** 방법이다.
- 한 개 이상의 독립변수 (설명변수)가 있다: X_1, X_2, \dots, X_K
- 한 개의 종속변수 (반응변수)가 있다: Y
- 종속변수의 값은 **0** 또는 **1**이다: 이분법적인 상황을 모델링한다.
- 조건부 확률 예측에 기반하여 종속변수의 값 (0 or 1)을 예측한다.

로지스틱회귀 기초

- K 개의 독립변수 (설명변수)가 있다고 가정한다.

⇒ 임의의 실수 값을 가질 수 있다.

$$X_1, X_2, \dots, X_K$$

로지스틱회귀 기초

- 그리고 한개의 종속변수가 있다고 가정한다.
⇒ 그런데 가능한 값은 0과 1로 국한되어 있다.

$$Y = \begin{cases} 1 \\ 0 \end{cases}$$

로지스틱회귀 기초

- 즉, 이분법적인 상황이다.

$$Y = \begin{cases} \text{참 (True)} \\ \text{거짓 (False)} \end{cases}$$

로지스틱회귀 기초


- 즉, 이분법적인 상황이다.

$$Y = \begin{cases} \text{유형 } a \\ \text{유형 } b \end{cases}$$

로지스틱회귀 원리

- 이제는 독립변수 $\{X_i\}$ 를 선형조합하여 S 변수 (logit)을 만든다.

$$S = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K$$



독립변수
(데이터로 값이 주어짐)

로지스틱회귀 원리

- 종속변수 Y 의 값이 1이 될 조건부 확률 $P(Y = 1|\{x_i\})$ 은 “로지스틱 함수”또는 “Sigmoid 함수”를 사용해서 계산된다.


$$f(S) = \frac{e^S}{1 + e^S}$$

⇒ 인공신경망에서 “활성화 함수” (activation function)의 역할을 한다.

⇒ Logit S 와 확률 P 사이의 관계는 다음과 같다.

$$S = \text{Log} \left(\frac{P}{1 - P} \right)$$

로지스틱회귀 원리



로지스틱회귀 학습

- 학습이란 모형의 파라미터, β_i 계수들의 값을 구하는 것을 의미한다.

$$S = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_K X_K$$

$$f(S) = \frac{e^S}{1+e^S}$$

로지스틱회귀 학습

- 로그우도 L 을 최소화하는 방법으로 β_i 계수들의 값을 구할 수 있다.
- 로그우도 L 은 일종의 “손실함수”이다.
 - ⇒ 예측 오류에 의한 “손실”을 최소화 하고자 한다.

로지스틱회귀 학습

- 로그우도 L 의 수식은 다음과 같다:

$$L(\vec{\beta}) = - \sum_{i=1}^N \text{Log} \left(1 + e^{-y_i \vec{\beta}^t \vec{x}_i} \right)$$

- L 의 값은 gradient 방향으로 증가율 최고.
 \Rightarrow 그리고 -gradient 방향으로는 감소율 최고.

로지스틱회귀 학습

- L 의 gradient는 다음과 같이 계산할 수 있다.

$$\vec{\nabla} L = - \sum_{i=1}^N \frac{y_i \vec{x}_i e^{-\vec{\beta}^t \vec{x}_i}}{1 + e^{-\vec{\beta}^t \vec{x}_i}}$$

$\Rightarrow L$ 을 미분하여 구할 수 있다.


$\Rightarrow \vec{x}_i$ 와 y_i 는 실제 데이터 값을 의미한다.

로지스틱회귀 학습


- Gradient descent 알고리즘은 손실함수 $L(\vec{\beta})$ 를 수렴적으로 최소화 시켜준다.
 - $\Rightarrow \vec{\beta}$ 를 감소율이 최고인 $-\nabla L(\vec{\beta})$ 방향으로 조금씩 이동시켜 간다.
 - a). $\vec{\beta}$ 를 임의의 값으로 초기화 한다.
 - b). Gradient ∇L 를 계산한다.
 - c). $\vec{\beta}$ 를 $\vec{\beta} - \eta \nabla L$ 와 같이 갱신한다. “Learning rate” η 로 수렴 속도 조절.
 - d). 스텝 b)로 돌아가서 일정 횟수만큼 반복한다.

로지스틱회귀 학습

- Gradient descent 알고리즘은 손실함수 $L(\vec{\beta})$ 를 수렴적으로 최소화 시켜준다.
 $\Rightarrow \vec{\beta}$ 를 감소율이 최고인 $-\nabla L(\vec{\beta})$ 방향으로 조금씩 이동시켜 간다.




로지스틱회귀 학습



모델의 파라미터, 즉 $\{\beta_i\}$ 를 학습용 데이터를 사용하여 계산해 놓는다.

로지스틱회귀 예측



독립변수의 값들 $\{x_i'\}$ 이 새롭게 주어졌을 때, 모르는 상태인 종속변수의 값 y' 을 계산을 통해서 알아낸다.

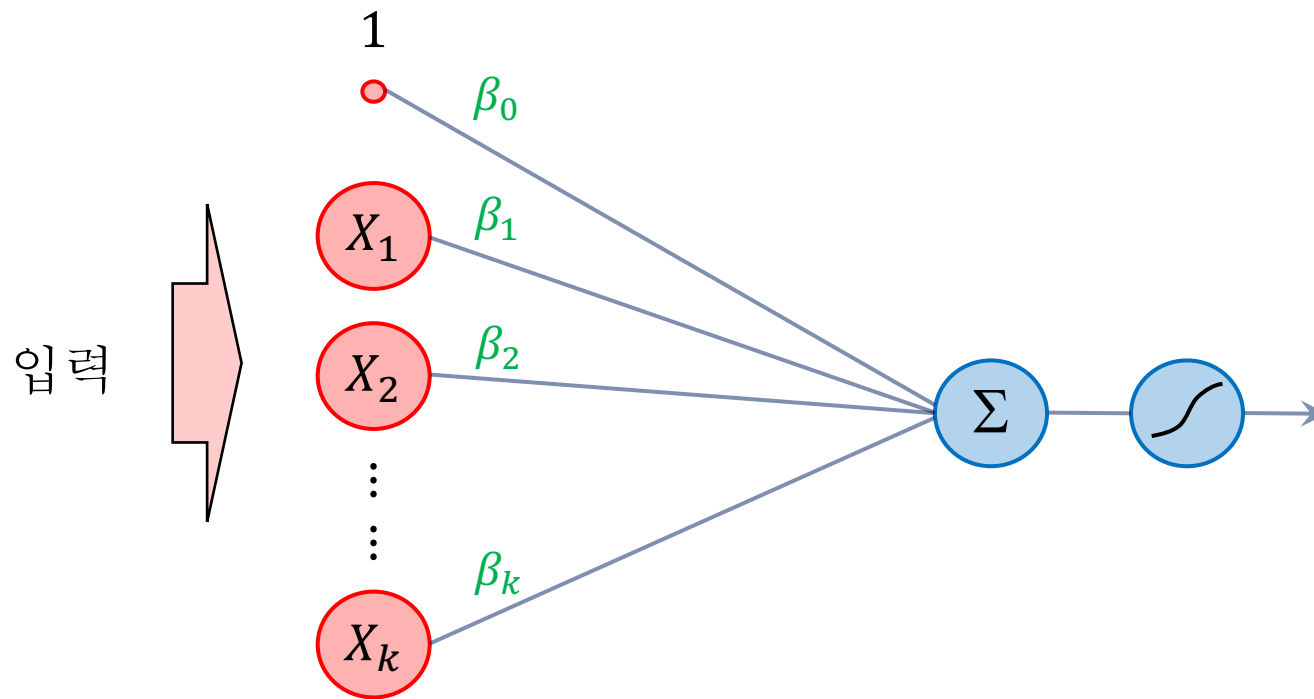


“조건부 확률”


$P(Y' = 1|\{x_i'\}) > \text{기준확률?}$

$\rightarrow \hat{y}' = 1 \text{ or } 0$

로지스틱회귀 예측



로지스틱회귀 예측



로지스틱회귀 평가

키포인트

- 혼동행렬 (confusion matrix).
- 정확도, 민감도, 특이도, 정밀도.
- ROC 곡선의 원리. \Rightarrow 기준확률과의 관계
- ROC 곡선과 AUC.
- 베이즈 정리를 활용한 예측결과 해석.

혼동행렬

	<i>Actual 0</i>	<i>Actual 1</i>
<i>Predicted 0</i>	134	42
<i>Predicted 1</i>	10	14

정확도 (Accuracy)

	<i>Actual 0</i>	<i>Actual 1</i>
<i>Predicted 0</i>	134	42
<i>Predicted 1</i>	10	14

⇒ 정확도는 행렬의 대각선의 합과 전체의 합 사이의 비율.

⇒ 예측된 유형이 실제 유형과 일치하는 비율.

정확도의 맹점

- 그런데 정확도 만으로 테스트가 불가능한 상황이 종종 발생한다.

예). 은행 대출고객 중에서 3% ~ 5%만이 향후 신용불량인 경우.

⇒ 목표는 소수인 신용불량 고객을 사전에 검출하는 것.

⇒ 만약에 모두를 신용양호로 예측한다면 정확도는 매우 높다!

⇒ 하지만 신용불량 고객은 한 명도 예측하지 못한다.

성능 지표

- Accuracy (정확도) = $\frac{\text{정확하게 예측된 개수}}{\text{전체 개수}}$
- Sensitivity (민감도) = $\frac{\text{정확하게 예측된 1의 개수}}{\text{실제 1의 총 개수}}$
- Specificity (특이도) = $\frac{\text{정확하게 예측된 0의 개수}}{\text{실제 0의 총 개수}}$

성능 지표

- Precision (정밀도) = $\frac{\text{정확하게 예측된 1의 개수}}{\text{1이라고 예측된 개수}}$
- Recall (재현율) = 민감도와 같은 의미
- Cohen의 카파 $\kappa = \frac{\text{Accuracy} - p_e}{1 - p_e}$ $\leftarrow p_e$ 는 우연으로 맞을 확률.

민감도 (Sensitivity)

	<i>Actual 0</i>	<i>Actual 1</i>
<i>Predicted 0</i>	134	42
<i>Predicted 1</i>	10	14

⇒ 민감도는 실제 1 중에서 정확하게 1이라 예측된 비율.

특이도 (Specificity)

	<i>Actual 0</i>	<i>Actual 1</i>
<i>Predicted 0</i>	134	42
<i>Predicted 1</i>	10	14

⇒ 특이도는 실제 0 중에서 정확하게 0이라 예측된 비율.

정밀도 (Precision)


	<i>Actual 0</i>	<i>Actual 1</i>
<i>Predicted 0</i>	134	42
<i>Predicted 1</i>	10	14

⇒ 정밀도는 1이라 예측된 경우 중에서 정답의 비율.

성능 지표

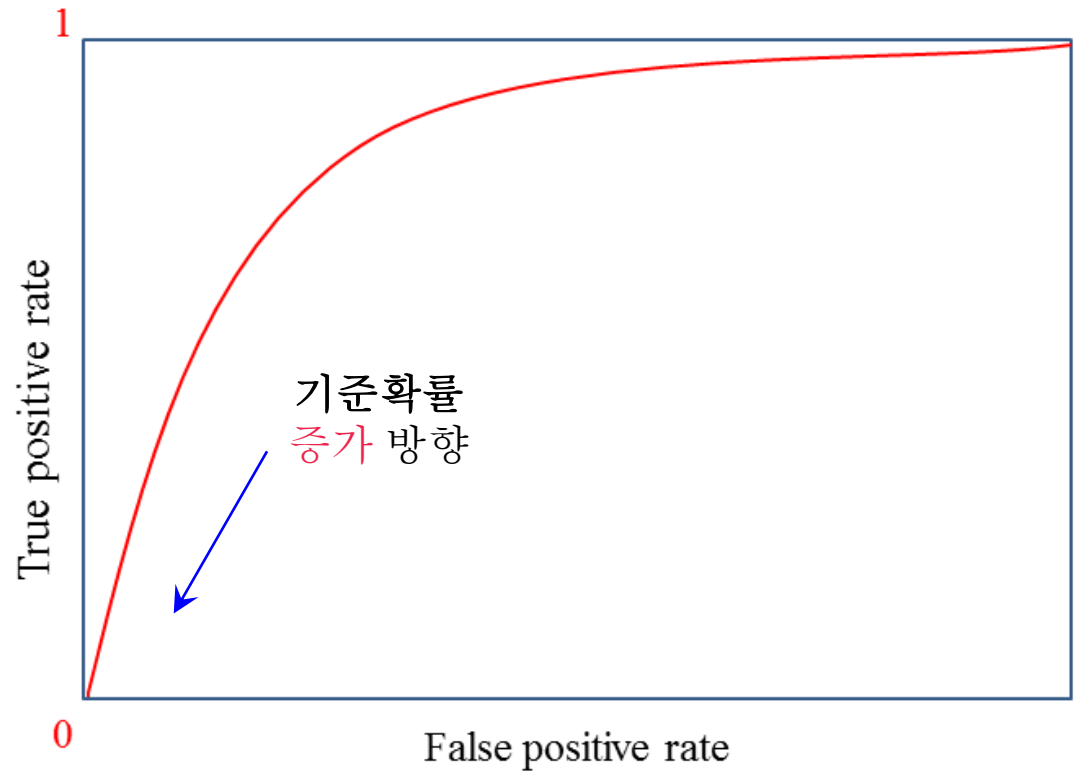
- True Positive Rate = Sensitivity
- True Negative Rate = Specificity
- False Positive Rate = $\frac{\text{실제는 0 이지만 1로 오인식된 개수}}{\text{실제 0의 개수}} = 1 - \text{Specificity}$
- False Negative Rate = $\frac{\text{실제는 1 이지만 0으로 오인식된 개수}}{\text{실제 1의 개수}} = 1 - \text{Sensitivity}$
- Positive Predicted Value = Precision

ROC 곡선



⇒ ROC 곡선은 기준확률에 대한 parametric plot이다.


ROC 곡선



기준확률이 증가 (1에 가까워 진다)	
성능척도	방향
민감도 (True Positive)	↓
특이도	↑
1-특이도 (False Positive)	↓
정밀도	↑

⇒ ROC 곡선은 기준확률에 대한 parametric plot이다.

ROC 곡선



기준확률이 감소 (0에 가까워 진다)	
성능척도	방향
민감도 (True Positive)	↑
특이도	↓
1-특이도 (False Positive)	↑
정밀도	↓

⇒ ROC 곡선은 기준확률에 대한 parametric plot이다.

ROC 곡선과 AUC



⇒ AUC는 곡선 아래의 면적 (**A**rea **U**nder the **C**urve)을 의미한다.

⇒ AUC가 클수록 (1에 가까울수록) 예측성능이 좋은 것이다.

로지스틱회귀 예측과 베イズ 정리

문제: 500개의 관측치가 있다. 이 중에서 종속변수의 값이 1인 경우는 30회이고 0인 경우는 나머지 470회이다. 그런데 로지스틱회귀 모형의 민감도는 0.92이고 특이도는 0.90이다. 만약에 이 모형을 가지고 한 예측결과가 1이라면 어느정도 믿을 수 있겠는가?

로지스틱회귀 예측과 베イズ 정리

문제: 500개의 관측치가 있다. 이 중에서 종속변수의 값이 1인 경우는 30회이고 0인 경우는 나머지 470회이다. 그런데 로지스틱회귀 모형의 민감도는 0.92이고 특이도는 0.90이다. 만약에 이 모형을 가지고 한 예측결과가 1이라면 어느정도 믿을 수 있겠는가?

이 문제의 조건을 정리해 보면 다음과 같다.

$$P(\text{예측 } 1 | \text{실제 } 1) = 0.92 \quad \text{“민감도”}$$

$$P(\text{예측 } 0 | \text{실제 } 0) = 0.90 \quad \text{“특이도”}$$

$$\Rightarrow P(\text{예측 } 1 | \text{실제 } 0) = 1 - P(\text{예측 } 0 | \text{실제 } 0) = 0.10$$

$$P(1) = 30/500 = 0.06$$

로지스틱회귀 예측과 베イズ 정리

문제: 500개의 관측치가 있다. 이 중에서 종속변수의 값이 1인 경우는 30회이고 0인 경우는 나머지 470회이다. 그런데 로지스틱회귀 모형의 민감도는 0.92이고 특이도는 0.90이다. 만약에 이 모형을 가지고 한 예측결과가 1이라면 어느정도 믿을 수 있겠는가?

그러므로 이 문제가 요구하는 답은 $P(\text{실제 1}|\text{예측 1})$ 이다. 예측 이것을 베イズ 정리를 적용하여 계산해 보면 다음과 같다.

$$\begin{aligned} P(\text{실제 1}|\text{예측 1}) &= \frac{P(\text{예측 1}|\text{실제 1})P(1)}{P(\text{예측 1}|\text{실제 1})P(1) + P(\text{예측 1}|\text{실제 0})P(0)} \\ &= \frac{0.92 \times 0.06}{0.92 \times 0.06 + 0.1 \times 0.94} \cong \mathbf{0.37} \end{aligned}$$

끝

