

# 확률과 통계

## 섹션 - 8

강사 : James 쌤



유료 강의자료입니다. 지은이의 허락없이 무단 복제와 배포를 엄격히 금합니다.

# 마르코프 연쇄

# 키포인트

---

- 확률과정.
- 전이행렬.
- 마르코프 연쇄 (Markov chain).

# 확률과정

---

- 시간이 지남에 따라서 변하는 확률변수의 집합을 의미한다.
  - ⇒ 상태가 확률적으로 변하고 이것에 대한 정보를 모아 놓은 집합이다.
  - ⇒ 예를 들어서 “마르코프 연쇄”는 이산 확률과정이다.


$$\{X_t, \dots, X_1, X_0\}$$

# 확률과정

- 마르코프 연쇄는 시간이 이산적인 확률과정이다.
- 마르코프 연쇄에서는 미래의 확률이 바로 한 스텝 이전의 상태에 의해서 결정된다.

$$P(x_{t+1}|x_t, x_{t-1}, x_{t-2}, \dots, x_1) = P(x_{t+1}|x_t)$$

예). 오늘 S사의 주가가 상승했으면 내일도 95%의 확률로 주가가 오를것 이다. 또한, 오늘 S사의 주가가 하락했더라도 내일은 20%의 확률로 주가가 오를 것이다.



# 전이행렬

- 전이행렬을 사용해서 확률과정을 묘사할 수 있다.

예). 오늘 S사의 주가가 상승했으면 내일도 95%의 확률로 주가가 오를것 이다. 또한, 오늘 S사의 주가가 하락했더라도 내일은 20%의 확률로 주가가 오를 것이다.

$$\tilde{T} = \begin{matrix} & \begin{matrix} \text{내일} \\ \text{상승} & \text{하락} \end{matrix} \\ \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} & \begin{matrix} \text{상승} \\ \text{하락} \end{matrix} \end{matrix} \quad \text{오늘}$$

# 전이행렬

---

- 전이행렬의 원소는 상태  $s_i$  에서  $s_j$ 로 전이되는 확률을 나타낸다.

$$T_{i,j} = P(x_{t+1} = s_j | x_t = s_i)$$

- 전이행렬의 행방향으로 합은 1이 되어야 한다.

$$\tilde{T} = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix}$$

# 전이행렬

---

- 전이행렬의 원소는 상태  $s_i$  에서  $s_j$ 로 전이되는 확률을 나타낸다.

$$T_{i,j} = P(x_{t+1} = s_j | x_t = s_i)$$

- 전이행렬의 행방향으로 합은 1이 되어야 한다.

$$\tilde{T} = \begin{bmatrix} 0.95 + 0.05 \\ 0.2 \quad 0.8 \end{bmatrix} = 1$$



# 전이행렬

---

- 전이행렬의 원소는 상태  $s_i$  에서  $s_j$ 로 전이되는 확률을 나타낸다.

$$T_{i,j} = P(x_{t+1} = s_j | x_t = s_i)$$

- 전이행렬의 행방향으로 합은 1이 되어야 한다.

$$\tilde{T} = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} = 1$$

# 전이행렬

---

- 전이행렬은 현재 상태를 1 타임스텝 전진시켜 준다.

$$x_{t+1} = x_t \tilde{T}$$


예).  $x_t = (1 \ 0)$  이고  $\tilde{T} = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix}$  라면,

$$x_{t+1} = (1 \ 0) \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} = (0.95 \ 0.05)$$

# 전이행렬과 확률나무

- 다음 전이행렬에 해당하는 확률나무를 만들어 본다.

$$\tilde{T} = \begin{matrix} & \begin{matrix} \text{내일} \\ \text{상승} & \text{하락} \end{matrix} \\ \begin{matrix} \text{오늘} \\ \text{상승} \\ \text{하락} \end{matrix} & \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} \end{matrix}$$



$s_1 =$  상승 상태.

$s_2 =$  하락 상태.

# 전이행렬과 확률나무

---

- 2 스텝 이후의 확률변화는 전이행렬을 두 번 적용한 것과 같다 (행렬 곱).


$$x_{t+2} = x_{t+1} \tilde{T} = x_t \tilde{T} \tilde{T} = x_t \tilde{T}^2$$

$$\tilde{T}^2 = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} = \begin{bmatrix} 0.9125 & 0.0875 \\ 0.35 & 0.65 \end{bmatrix}$$

# 전이행렬과 확률나무

- 2 타임 스텝 전이행렬과 확률나무.

$$\tilde{T}^2 = \begin{bmatrix} 0.9125 & 0.0875 \\ 0.35 & 0.65 \end{bmatrix}$$



$s_1$ 끼리 더하면 확률 = 0.9125

$s_2$ 끼리 더하면 확률 = 0.0875

# 전이행렬의 안정상태

- 전이행렬을 거듭해서 곱해서 적용하다 보면 다음과 같이 **변화가 멈춘 상태**가 될 수 있다. 이것을 **안정상태** (steady state)라 부른다.

$$\tilde{T}^i = \tilde{T}^{i+1} = \tilde{T}^{i+2} = \dots$$

$$\text{예). } \tilde{T} = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} \Rightarrow \tilde{T}^{100} = \tilde{T}^{101} = \tilde{T}^{102} = \dots$$

$$= \begin{bmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{bmatrix}$$

# 마르코프 의사결정 과정

# 키포인트

---

- 마르코프 의사결정 과정 (Markov Decision Process, MDP).
- 행동, 상태, 보상, 전이확률, 감가율.
- 반환값.
- 격자 세상 (Grid world).



# 마르코프 의사결정 과정 : 개요

---

- 순차적 행동결정 문제를 수학적으로 모델링한 것이다.  $\Rightarrow$  정책의 최적화
- 환경은 전체가 완전히 관찰 가능해야 한다.
- 현재 상태가 과정의 특성을 모두 반영하여야 한다. 미래의 상태는 현재의 상태에 의해서 결정되고 더 이상의 과거는 돌아볼 필요가 없다.  $\Leftarrow$  마르코프 연쇄를 전제
- 마르코프 의사결정 과정의 해는 **다이내믹 프로그래밍** 방법 또는 **강화학습** 방법으로 구할 수 있다.

**주의:** 실제 구현하기 보다는 개념 위주로 알아본다.

# 마르코프 의사결정 과정 : 개요

---

예). 게임에서는 현 상태에서 그 다음의 최적 움직임을 결정해야 한다.



# 마르코프 의사결정 과정 : 개요

---

예). 투자에서는 현 상태에서 그 다음의 최적 움직임을 결정해야 한다.



# 마르코프 의사결정 과정 : 용어

---

- 에이전트 (agent): 환경과 상호작용하는 알고리즘 또는 시스템.
- 정책 (policy): 정책은 특정 상태에서 에이전트가 취해야 할 행동을 정의한다. 즉, 상태에 행동을 매핑해 놓은 것이다. 정책은 확정적일 수도 있고, 확률적일 수도 있다.

??

Left??

Right??



# 마르코프 의사결정 과정 : 정의

---

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, A, P^a, R^a, \gamma)$$

- MDP 는 조건부 확률에 대한 주장이다. **마르코프 과정을 따른다는 가정**하에 상태  $S_{t+1}$ 은 바로 이전의 상태  $S_t$ 에 대한 조건으로 만들어 진다. 이것을 수식으로 다음과 같이 표현할 수 있다.

$$P(S_{t+1}|S_t, S_{t-1}, S_{t-2}, \dots, S_1) = P(S_{t+1}|S_t)$$

# 마르코프 의사결정 과정 : 상태

---

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (\mathbf{S}, A, P^a, R^a, \gamma)$$

$\Rightarrow \mathbf{S} = \{s_1, s_2, s_3, \dots\}$  : 에이전트가 취할 수 있는 상태 (state)의 집합.

# 마르코프 의사결정 과정 : 행동

---

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, \mathbf{A}, P^a, R^a, \gamma)$$

⇒  $\mathbf{A} = \{a_1, a_2, a_3, \dots\}$  : 에이전트가 취할수 있는 행동 (action)의 집합.

⇒ 특정 시점  $t$  에서 행동  $a$ 를 취하는 경우  $A_t = a$ 와 같이 표기한다.

⇒ 격자세상 (grid world)에서는  $A = \{\text{위, 아래, 왼쪽, 오른쪽}\}$ 과 같다.

# 마르코프 의사결정 과정 : 전이확률

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, A, \mathbf{P}^a, R^a, \gamma)$$

$\Rightarrow \mathbf{P}_{ss'}^a = P(S_{t+1} = s' | S_t = s, A_t = a)$  : 시점  $t$ 에서 행동  $a$ 를 취한 경우 상태가  $s$ 에서  $s'$ 로 전이되는 확률이다.

$\Rightarrow$  환경과 에이전트의 상호작용 : 에이전트가 행동을 취하면 전이확률을 통해서 다음으로 에이전트가 갈수 있는 상태를 알려준다.



# 마르코프 의사결정 과정 : 보상

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, A, P^a, \mathbf{R}^a, \gamma)$$

⇒  $\mathbf{R}_s^a = E[R_{t+1} | S_t = s, A_t = a]$  : 시점  $t$ 의 상태  $s$ 에서 행동  $a$ 를 취한 대가로 에이전트가 받는 보상이다.

⇒  $\mathbf{R}_s^a$ 와 같이 표기함은 기대값의 의미로의 보상이고  $R_t, R_{t+1}$ 등과 같이 표기함은 확률 변수의 의미로의 보상이다.

⇒ 시점  $t$ 에서의 행동에 따라서 보상이 전달되는 시점은  $t + 1$ 이다.

# 마르코프 의사결정 과정 : 감가율

---

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, A, P^a, R^a, \gamma)$$

⇒  $\gamma$  : 과거 또는 미래의 행동에 대한 보상을 얼마만큼 반영할지 정하는 0과 1사이의 수치. 감마의 소문자 사용.

⇒ 예를 들어서  $\gamma = 0.9$  라면  $\gamma^2 = 0.81, \gamma^3 = 0.729, \dots$  과 같다.

# 마르코프 의사결정 과정 : 감가율

- 마르코프 의사결정 과정 (MDP)은 다음과 같이 정의된다.

$$MDP = (S, A, P^a, R^a, \gamma)$$

⇒ 현재 시점  $t$ 에서  $k$ 만큼 지난 후에 보상  $R_{t+k}$ 을 받는다면  $\gamma^{k-1}$ 만큼의 감가가 적용된다. 미래의 가치를 현재의 가치로 환산하는 것과도 같다.

⇒ 할인된 미래  $t+k$ 의 보상 =  $\gamma^{k-1}R_{t+k}$ .


⇒ 다음과 같이 감가된 총 미래 보상 “반환값”을 정의할 수 있다.

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

# 격자세상 (Grid World)

- 다음과 같이 상태의 집합  $S$ 와 행동의 집합  $A$ 가 있다고 가정해 본다.

$s_1$ 출발점	$s_2$	$s_3$ 함정
$s_4$	$s_5$	$s_6$
$s_7$ 함정	$s_8$	$s_9$ 목적지




- 감가율  $\gamma = 0.9$ 임을 전제한다.

# 격자세상 (Grid World)

- 다음과 같은 보상 구조를 전제한다.

-0.02 출발점	-0.02	-1 함정
-0.02	-0.02	-0.02
-1 함정	-0.02	+1 목적지




- 예를 들어서  $s_1$ 에서 행동  $a_2$ 를 연이어서 두번 취해서 상태를  $s_1 \rightarrow s_2 \rightarrow s_3$ 와 같이 변이 하여 함정에 빠졌다면, -0.02, -1 과 같은 순서로 보상을 받는다.

# 격자세상 (Grid World)

- 다음과 같은 보상 구조를 전제한다.

-0.02 출발점	-0.02	-1 함정
-0.02	-0.02	-0.02
-1 함정	-0.02	+1 목적지



- 이런 경우 감가율을 적용한 반환값은  $-0.02 + 0.9 \times (-1) = -0.92$ 와 같다.

# 베이지스 통계

# 키포인트

---

- 베이지 정리와 베이지 통계.
- 사전확률과 사후확률.
- 우도함수.
- 켈레 사전 확률분포 (conjugate prior).




# 베이지스 통계

- 통계학에서는 크게 두가지 접근 방법이 있다.

⇒ 고전 통계:

- ✓ 확정적인 모집단과 모수 ( $\mu, \sigma^2$  등) 전제. 표본으로 추론한다.
- ✓ 과거 데이터 분석.



모집단

# 베이즈 통계

---

- 통계학에서는 크게 두가지 접근 방법이 있다.

⇒ 고전 통계:


“우리가 지금까지 강의를 통해서 배워온 통계”

# 베이지스 통계

- 통계학에서는 크게 두가지 접근 방법이 있다.

⇒ 베이지스 통계:

- ✓ 모수  $\theta$ 를 **확률적으로 묘사**하며 실증적이며 주관적인 전제를 포함한다.
- ✓ 현재 진행형 데이터 분석.



# 베이즈 통계

---

- 통계학에서는 크게 두가지 접근 방법이 있다.

⇒ 베이즈 통계:


“베이즈 통계를 제대로 다루려면 **많은 시간**이 필요하다”

“이번 강의에서는 **간략하게** 그 취지와 원리에 대해서 알아본다”

# 베イズ 통계 원리

---

- 사전 확률 (prior)를 전제하고 새로운 증거 (data)를 가지고 갱신해서 사후 확률 (posterior)를 얻는다.



# 베이즈 통계 원리

---

- 베이즈 정리를 다시 한번 살펴본다.
- 상기해 보면 확률의 곱셈법칙을 변형하여 베이즈 정리를 도출해 낼 수 있었다.

$$P(A|B)P(B) = P(A \cap B) = P(B|A)P(A)$$




$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

# 베이지 통계 원리

---

- “사건”의 표본공간  $S$ 는 서로 교차하지 않는 부분집합  $A_1, A_2, \dots, A_K$ 로 이루어져 있다고 전제한다.  $\Rightarrow$  한정적 가짓수  $K$ , 즉 “이산적”인 경우.


$$S = A_1 \cup A_2 \cup \dots \cup A_K$$



# 베이지 통계 원리

- 그러면 특정 사건  $B$ 는 다음과 같은 부분들의 합집합이다.

$$B = (B \cap A_1) \cup (B \cap A_2) \cup \cdots \cup (B \cap A_K)$$



- 곱셈법칙  $P(B \cap A_i) = P(B|A_i)P(A_i)$ 을 적용해서  $P(B)$ 를 다음과 같이 표현할 수 있다.

$$P(B) = P(B|A_1)P(A_1) + P(B|A_2)P(A_2) + \cdots + P(B|A_K)P(A_K) = \sum_{j=1}^K P(B|A_j)P(A_j)$$



# 베이즈 통계 원리

---

- 그리고, 베이즈 정리를 다음과 같이 나타낼 수 있다.

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{P(B)} = \frac{P(B|A_i) P(A_i)}{\sum_{j=1}^K P(B|A_j)P(A_j)}$$

# 베이즈 통계 원리

- 그리고, 베이즈 정리를 다음과 같이 나타낼 수 있다.

$$\boxed{P(A_i|B)} = \frac{P(B|A_i)P(A_i)}{P(B)} = \frac{\boxed{P(B|A_i)}\boxed{P(A_i)}}{\sum_{j=1}^K P(B|A_j)P(A_j)}$$

우도함수

사전확률

사후확률

⇒ 사전확률은 **주관적인** 사전 지식을 반영한다.

# 베이지스 통계 원리

---

- 이산의 경우와 유사하게 연속변수  $\theta$ 에 대한 조건부 확률도 다음과 같이 구할 수 있다.

$$\pi(\theta|x) = \frac{f(x|\theta) \pi(\theta)}{f(x)}$$

$$\Rightarrow f(x) = \int f(x|\theta') \pi(\theta') d\theta'$$

$\Rightarrow x$ 는 데이터를 의미한다.

# 베이지스 통계 원리

- 이산의 경우와 유사하게 연속변수  $\theta$ 에 대한 조건부 확률도 다음과 같이 구할 수 있다.

우도함수                      사전확률밀도

사후확률밀도  $\rightarrow \pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{f(x)}$

$\propto f(x|\theta)\pi(\theta)$

$\Rightarrow$  사전확률밀도는 주관적인 사전 지식을 반영한다.

$\Rightarrow$  중요한 것은 등호 오른편 분자와의 비례관계이다.

# 베이지스 통계 원리

---

- 연속변수  $\theta$ 가 모수를 나타낸다면 사후확률밀도  $\pi(\theta|x)$ 를 사용하여 모수의 기대값 (평균)을 구할 수 있다.  $\rightarrow$  “ $\theta$ 의 모평균”

$$E[\theta|x] = \int \theta' \pi(\theta'|x) d\theta'$$

$\Rightarrow$  모수는 더이상 확정적이지 아니며 확률적으로 묘사한 것이 된다.

$\Rightarrow$  사전 지식에 실증적 데이터  $x$ 를 가미하여 얻은 결과이다.

# 컬레 사전 확률분포

- 사전확률분포와 사후확률분포가 동일한 종류의 확률분포에 속하는 경우.

예). 사전, 사후확률분포 둘 다 베타확률 분포가 되는 경우가 있다.

베타확률 분포로 사전확률을 표현하면 사후확률도 베타확률 분포이다.

- 그런데, 모든 경우에 컬레 사전 확률분포가 존재하는 것은 아니다.

⇒ 우도함수가 “적절한” 형태 이어야만 한다.

⇒ 적절한 우도함수가 주어지면 컬레 사전 확률분포를 선택해서 쉽게 사후확률분포를 계산할 수 있다.

# 컬레 사전 확률분포

- 적절한 우도함수가 주어지면 컬레 사전 확률분포를 선택해서 쉽게 사후확률분포를 계산할 수 있다.

우도함수	컬레 사전 확률분포
이항확률분포	베타확률분포
정규확률분포 (모분산 $\sigma^2$ 을 알 때)	정규확률분포
정규확률분포 (모평균 $\mu$ 을 알 때)	역감마분포
푸아송분포	감마분포
⋮	⋮

# 결레 사전 확률분포 예시

---

- 우도함수가 이항 확률분포로 주어질 수 있는 상황을 전제해 본다.
  - ⇒ 이항 확률분포는 이분법적 상황에서  $n$ 회 시행하여 “성공”한 횟수  $x$ 에 대한 확률을 계산해 준다.
  - ⇒ 우도함수를 다음 이항 확률분포로 모델링할 수 있는 경우를 전제해 본다.

$$f(x|\theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x} \quad \leftarrow \theta \in [0,1]$$

$$\propto \theta^x (1 - \theta)^{n-x}$$



# 결레 사전 확률분포 예시

---

- 그러면 사전확률분포로 베타확률분포를 선택해서 표현한다.  $C$ 는 상수이다.

$$\pi(\theta) = C \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

⇒ 베타확률분포  $Beta(\alpha, \beta)$ 에는 두개의 파라미터  $\alpha, \beta$ 가 있다.

⇒ 베타확률분포  $Beta(\alpha, \beta)$ 의 평균은  $\frac{\alpha}{\alpha+\beta}$ 이다.

# 컬레 사전 확률분포 예시

- 우도함수와 사전확률분포를 곱해서 사후확률분포를 구한다.

⇒  $C'$ 에는 우도함수의 상수, 사전확률분포의 상수, 분모 등이 흡수되어 있다.

$$\pi(\theta|x) = C' f(x|\theta) \pi(\theta)$$

$$= C' \theta^x (1 - \theta)^{n-x} \times \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

$$= C' \theta^{\alpha+x-1} (1 - \theta)^{\beta+n-x-1}$$

⇒ 이것은 또다른 베타확률분포  $Beta(\alpha + x, \beta + n - x)$ 이다. 확인!

⇒ 사후확률분포의 평균은  $\frac{\alpha+x}{\alpha+\beta+n}$ 이다. 즉,  $\theta$ 의 평균이 갱신되었다!

# 컬레 사전 확률분포 예시


- 정리해 보면,
  - 1). 모수  $\theta$ 는 베타확률  $Beta(\alpha, \beta)$ 로 묘사 할 수 있다는 **사전지식**이 있었다.
  - 2).  $n$ 회 시행해서  $x$ 회 성공했다는 **데이터**가 있다.
  - 3). 사전지식과 데이터를 “융합”하여 **사후지식**을 얻었다.
  - 4). “모수  $\theta$ 는  $Beta(\alpha', \beta')$ 로 묘사 가능하다”가 바로 **사후지식**이다.

여기서  $\alpha' = \alpha + x$ 이며  $\beta' = \beta + n - x$  이다.

- 사후확률분포를 다음 라운드에서는 사전확률분포로 사용할 수 있다!

# 컬레 사전 확률분포 - 구체적인 예


- 어느 자산의 가격이 상승(up) 또는 하락(down) 두 방향으로 변동할 수 있는 상황.
  - $\Rightarrow \theta$ 는 자산의 가격이 **상승할 확률**이며 관심 대상인 **모수**이다.  $\theta \in [0,1]$  이다.
  - $\Rightarrow$  이분법적 상황. 그러므로: 우도함수 = 이항확률 & 사전확률 = 베타.



# 컬레 사전 확률분포 - 구체적인 예

- 사전지식이 전무한 경우 사전확률분포는  $Beta(1,1) = 1$ 이다.

$$\Rightarrow \theta \text{의 기대값} = \frac{\alpha}{\alpha+\beta} = \frac{1}{1+1} = 0.5$$




- 만약에  $\theta$ 에 대해서 **유용한 사전지식**이 있다면  $\alpha$ 와  $\beta$ 에 반영할 수도 있다!

# 컬레 사전 확률분포 - 구체적인 예

- 만약에 47회 관찰 했더니 32회 상승했고 15회 하락했다 한다면,  
⇒ 사후확률분포는  $Beta(33,16)$ 이다.

$\alpha' = 1 + 32 = 33$ 이며  $\beta' = 1 + 15 = 16$ 와 같이 갱신된다.

⇒  $\theta$ 의 기대값  $= \frac{\alpha'}{\alpha' + \beta'} = \frac{33}{33 + 16} \cong 0.67$



# 컬레 사전 확률분포 : 문제점

---

- 이전 예시는 정확한 수식으로 계산이 가능한 lucky한 경우에 해당한다.
- 그런데 컬레 사전확률이 없거나 수식으로 “쉽게” 계산할 수 없는 경우에는 어떻게 하는가? 어떻게 일반화 할 수 있는가?

# 컬레 사전 확률분포 : 문제점

---

- 이전 예시는 정확한 수식으로 계산이 가능한 간단한 경우에 해당한다.
- 그런데 컬레 사전확률이 없거나 수식으로 “쉽게” 계산할 수 없는 경우에는 어떻게 하는가? 어떻게 일반화 할 수 있는가?

⇒ 마르코프 연쇄 몬테카를로 방법을 사용할 수 있다!

⇒ 다음 강의에서 자세히 알아보도록 한다.



# 마르코프 연쇄 몬테카를로

# 키포인트

---


- 몬테카를로 적분.
- 베イズ 통계.
- 마르코프 불변 확률분포 (stationary distribution).
- 마르코프 연쇄 몬테카를로 (Markov Chain Monte Carlo, MCMC).

# 몬테카를로 적분 : 원리

---

- 다음 음영 부분의 면적을 구하고자 한다.


⇒ 적분? ⇒ 하지만 어렵다!



# 몬테카를로 적분 : 원리

- 다음 음영 부분의 면적을 구하고자 한다.

⇒ 다음과 같이 면적을 구하기 쉬운 직사각형으로 가두어 둔다.




← 직사각형의 면적 =  $A_{\square}$

# 몬테카를로 적분 : 원리

- 다음 음영 부분의 면적을 구하고자 한다.

⇒ 랜덤으로 좌표를 점으로 찍어 본다. “시물레이션”




⇒ 어떤 점은 음영 안에 있고 (파란색) 또한 어떤 점은 음영 바깥에 있다 (빨간색).

# 몬테카를로 적분 : 원리

- 다음 음영 부분의 면적을 구하고자 한다.


⇒ 랜덤으로 좌표를 점으로 찍어 본다. “시물레이션”



$$A_{\text{음영}} \cong \frac{N_{in}}{N_{tot}} \times A_{\square} \quad \left\{ \begin{array}{l} N_{in} = \text{음영 안의 점의 개수} \\ N_{tot} = \text{전체 점의 개수} \end{array} \right.$$

# 몬테카를로 적분 : 일반화

- 다음과 같이 구간  $[a, b]$  에서 정의된 확률 분포  $f(\theta)$ 를 가정한다



# 몬테카를로 적분 : 일반화

---

- 마찬가지로 구간  $[a, b]$ 에서 정의된 함수  $g(\theta)$ 에 대한 적분을 구하고자 한다.

$$I = \int_a^b g(\theta)f(\theta)d\theta$$



# 몬테카를로 적분 : 일반화

---

- 마찬가지로 구간  $[a, b]$ 에서 정의된 함수  $g(\theta)$ 에 대한 적분을 구하고자 한다.

$$I = \int_a^b g(\theta)f(\theta)d\theta$$

어렵다?

# 몬테카를로 적분 : 일반화

- 몬테카를로는 랜덤 넘버를 생성하여 **적분의 근사값**을 구하는 방법이다.

$$I = \int_a^b g(\theta)f(\theta)d\theta$$

$$\cong \frac{g(\theta^1)+g(\theta^2)+g(\theta^3)+\dots+g(\theta^M)}{M}$$

⇒  $\theta^1, \theta^2, \theta^3, \dots, \theta^M$ 은 확률분포  $f(\theta)$ 에 의해서 생성된 랜덤 넘버이다.

⇒ 고차원 적분도 쉽게 구할 수 있다는 장점이 있다.  $I = \int \int \int \dots dx_1 dx_2 \dots$

⇒ 몬테카를로 계산 오차  $\sim 1/\sqrt{M}$

# 베이지스 통계 기대값과 몬테카를로 적분

- 연속변수  $\theta$ 가 모수를 나타낸다면 사후 확률밀도  $\pi(\theta|x)$ 를 사용하여 모수의 기대값 (평균)을 구하려 한다. 수식 만으로 “쉽게” 계산할 수 없는 경우를 가정해 본다.

$$E[\theta|x] = \int \theta \pi(\theta|x) d\theta$$

$$\cong \frac{\theta^1 + \theta^2 + \theta^3 + \dots + \theta^M}{M}$$

⇒  $\theta^1, \theta^2, \theta^3, \dots, \theta^M$ 은 사후 확률밀도  $\pi(\theta|x)$ 을 따라서 랜덤으로 생성되었다.

⇒ 결론적으로 사후 확률밀도  $\pi(\theta|x)$ 의 랜덤 샘플링 방법이 필요하다!

# 마르코프 연쇄 : 전이행렬

- 전이행렬  $\tilde{T}$  는 현재 상태를 1 타임스텝 전진시켜 준다.

$$y_{t+1} = y_t \tilde{T}$$

- 전이행렬의 원소는 상태  $s_i$  에서  $s_j$  로 전이되는 확률을 나타낸다.

$$T_{i,j} = p(y_{t+1} = s_j | y_t = s_i)$$

$$\Rightarrow P(y_{t+1} = s_j) = \sum_i p(y_{t+1} = s_j | y_t = s_i) P(y_t = s_i) \quad \text{“이산 변수”}$$

$$\Rightarrow f(\theta_{t+1}) = \int \boxed{f(\theta_{t+1} | \theta_t)} f(\theta_t) d\theta_t \quad \text{“연속 변수”}$$

전이핵

# 마르코프 연쇄 : 안정상태와 불변 확률분포

- 전이행렬을 거듭해서 적용 (곱하기)하다 보면 다음과 같이 **변화가 멈춘 상태**가 될 수 있다. 이것을 **안정상태** (steady state)라 부른다.

$$\tilde{T}^i = \tilde{T}^{i+1} = \tilde{T}^{i+2} = \dots$$

예).  $\tilde{T} = \begin{bmatrix} 0.95 & 0.05 \\ 0.2 & 0.8 \end{bmatrix} \Rightarrow \tilde{T}^{100} = \tilde{T}^{101} = \tilde{T}^{102} = \dots = \tilde{T}_{steady}$

$$\tilde{T}_{steady} = \begin{bmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{bmatrix}$$

# 마르코프 연쇄 : 안정상태와 불변 확률분포

- 안정상태에 다다른 후에는 초기 상태가  $s_1 = (1 \ 0)$ 이건  $s_2 = (0 \ 1)$ 이건 동일한 확률분포를 보인다. → “불변 확률분포”

예).  $\tilde{T}_{steady} = \begin{bmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{bmatrix}$  일 때,


$$s_1 \tilde{T}_{steady} = (1 \ 0) \begin{bmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{bmatrix} = (0.8 \ 0.2)$$


$$s_2 \tilde{T}_{steady} = (0 \ 1) \begin{bmatrix} 0.8 & 0.2 \\ 0.8 & 0.2 \end{bmatrix} = (0.8 \ 0.2)$$

# 마르코프 연쇄 : 안정상태와 불변 확률분포

- 연속형 변수  $\theta$ 의 경우 이어서 여러 번 적분을 해줌으로서 불변확률분포  $f_s(\theta)$ 를 얻을 수 있다.

$$f(\theta_2) = \int f(\theta_2|\theta_1) f(\theta_1)d\theta_1$$


$$f(\theta_3) = \int f(\theta_3|\theta_2) f(\theta_2)d\theta_2$$


$$f(\theta_4) = \int f(\theta_4|\theta_3) f(\theta_3)d\theta_3$$

⋮

$$f_s(\theta)$$

# 마르코프 연쇄 : 안정상태와 불변 확률분포

---

- 연속형 변수  $\theta$ 의 경우 이어서 여러 번 적분을 해줌으로서 불변확률분포  $f_s(\theta)$ 를 얻을 수 있다.
- 다음과 같이 표현할 수도 있다.

$$f_s(\theta) = \int \cdots \int \cdots f(\theta_4|\theta_3)f(\theta_3|\theta_2)f(\theta_2|\theta_1)f(\theta_1)d\theta_1 d\theta_2d\theta_3 \cdots$$



# 마르코프 연쇄 몬테카를로 : 적분

- 사후 확률밀도  $\pi(\theta|x)$ 와 같은 “불변확률”을 갖는 “전이핵”  $f(\theta_{t+1}|\theta_t)$ 을 고안해서 몬테카를로 방법을 적용한다.

$$f_s(\theta) = \int \cdots \int \cdots f(\theta_4|\theta_3)f(\theta_3|\theta_2)f(\theta_2|\theta_1)f(\theta_1)d\theta_1 d\theta_2 d\theta_3 \cdots$$

$$f_s(\theta) \rightarrow \pi(\theta|x)$$


⇒ 사후 확률밀도  $\pi(\theta|x)$ 를 랜덤 샘플링 한 것과 같다. 결과는 샘플 (표본)이다!

⇒ 베イズ 기대값을 구할 수 있다.

# Metropolis-Hastings 알고리즘

---

- 1). 불변확률은 초기 상태와는 무관하므로 샘플링하기 편리한 확률분포  $f(\theta)$ 를 사용하여 첫 스텝에 해당하는  $\theta_1$ 의 표본을 확보해 둔다.



# Metropolis-Hastings 알고리즘

---

2). 샘플링하기 편리한 제안분포  $q(\theta|\theta_t)$ 를 선택한다.

⇒ 정규분포를 제안분포로 사용할 수 있다.  $d$ 는 임의의 양수이다.

$$q(\theta|\theta_t) = \frac{1}{\sqrt{2\pi}d} e^{-\frac{(\theta-\theta_t)^2}{2d^2}}$$

⇒ 이 경우  $q(\theta|\theta_t) = q(\theta_t|\theta)$ 와 같다.

# Metropolis-Hastings 알고리즘

3). 스텝  $t$ 에 해당하는 샘플이 있을 때 전이핵  $f(\theta_{t+1}|\theta_t)$ 을 다음 방식으로 샘플링하여 한 스텝 전진시킨다:  $t \rightarrow t + 1$ .

⇒ (정규분포) 제안분포를 샘플링하여  $\theta^*$ 를 얻고 사후확률의 비율  $r$ 을 구한다:

$$r = \frac{\pi(\theta^*|x)}{\pi(\theta_t|x)} = \frac{f(x|\theta^*) \pi(\theta^*)}{f(x|\theta_t) \pi(\theta_t)} \quad \left. \vphantom{\frac{\pi(\theta^*|x)}{\pi(\theta_t|x)}} \right\} \begin{array}{l} \text{분자와 분모에서} \\ \text{베이즈 정리 사용.} \end{array}$$

# Metropolis-Hastings 알고리즘

3). 스텝  $t$ 에 해당하는 샘플이 있을 때 전이핵  $f(\theta_{t+1}|\theta_t)$ 을 다음 방식으로 샘플링하여 한 스텝 전진시킨다:  $t \rightarrow t + 1$ .

⇒ (정규분포) 제안분포를 샘플링하여  $\theta^*$ 를 얻고 사후확률의 비율  $r$ 을 구한다:

$$r = \frac{\pi(\theta^*|x)}{\pi(\theta_t|x)} = \frac{\boxed{f(x|\theta^*)} \pi(\theta^*)}{\boxed{f(x|\theta_t)} \pi(\theta_t)}$$

우도함수.  
“전이핵” 아님!

# Metropolis-Hastings 알고리즘

3). 스텝  $t$ 에 해당하는 샘플이 있을 때 전이핵  $f(\theta_{t+1}|\theta_t)$ 을 다음 방식으로 샘플링하여 한 스텝 전진시킨다:  $t \rightarrow t + 1$ .

⇒ (정규분포) 제안분포를 샘플링하여  $\theta^*$ 를 얻고 사후확률의 비율  $r$ 을 구한다:

$$r = \frac{\pi(\theta^*|x)}{\pi(\theta_t|x)} = \frac{f(x|\theta^*) \pi(\theta^*)}{f(x|\theta_t) \pi(\theta_t)}$$

⇒  $r$ 이 1보다 크면  $\theta_{t+1} = \theta^*$ 와 같이 표본을 한스텝 전진시킨다.

⇒  $r$ 이 1보다 작으면  $U(0,1)$  랜덤넘버  $r'$ 을 생성해서,

$r \geq r'$ 이면  $\theta_{t+1} = \theta^*$ 와 같이 표본을 한 스텝 전진시키고

$r < r'$ 이면  $\theta_{t+1} = \theta_t$ 와 같이 한 스텝 전진시킨다.

0과 1 사이의  
연속균등분포.

# Metropolis-Hastings 알고리즘

---

- 4). 샘플을 여러 스텝 전진시키면 불변확률에 해당하는 샘플 (표본)을 얻게되고 이것이 바로 사후확률을 대표하게 된다. 이 샘플을 가지고 베イズ 기대값을 구할 수 있다.

$$E[\theta|x] \cong \frac{\theta_1 + \theta_2 + \theta_3 + \dots + \theta_M}{M}$$

# 은닉 마르코프 모델



# 키포인트

---

- 마르코프 연쇄.
- 은닉 마르코프 모델 (Hidden Markov Model, HMM).

# 은닉 마르코프 모델의 용도


---

- 통신에서 많이 사용되는 모형.
- 자연어 분석, 음성인식, 강화학습, 등 AI에서 많이 사용 됨.
- 금융 모델링에도 활용됨.

# 마르코프 과정

- 미래의 확률이 바로 한 스텝 이전과 연결되며 더 오래된 과거는 필요없다.

$$P(x_{t+1}|x_t, x_{t-1}, x_{t-2}, \dots, x_1) = P(x_{t+1}|x_t)$$




- 마르코프 연쇄는 시간이 이산적인 경우에 해당한다.
- 실제 상태는 직접 관찰 가능하다.

# 마르코프 과정 예시


- 다음 예를 그래프로 나타내 본다.

예). 오늘 S사의 주가가 상승했으면 내일도 95%의 확률로 주가가 오를것 이다. 또한, 오늘 S사의 주가가 하락했더라도 내일은 20%의 확률로 주가가 오를 것이다. 상승 상태는  $S_1$ 로 표기하고 하락 상태는  $S_2$ 로 표기한다.



# 마르코프 과정 예시

- 3 개의 관찰 가능한 상태  $S_1, S_2, S_3$  이 있는 경우.



⇒  $a_{ij}$  = 전이 확률.

⇒  $\sum_j a_{ij} = 1$ 이다.

# 마르코프 연쇄

- 다음과 같이 전이해 갈 확률은?

$$\begin{array}{c} t : \quad 1 \quad 2 \quad 3 \\ \hline S_1 \rightarrow S_2 \rightarrow S_1 \end{array}$$

$$\begin{aligned} \Rightarrow P(x_3 = S_1, x_2 = S_2, x_1 = S_1) \\ = p(x_3 = S_1 | x_2 = S_2) p(x_2 = S_2 | x_1 = S_1) P(x_1 = S_1) \end{aligned}$$

$\Rightarrow$  한 스텝씩 전진해 나가며 전이확률을 곱해준다.

- 일반화 해서  $x_1, x_2, x_3, \dots, x_T$ 와 같은 시퀀스의 확률은 다음과 같다.

$$P(x_T, \dots, x_3, x_2, x_1) = p(x_T | x_{T-1}) p(x_{T-1} | x_{T-2}) \cdots p(x_2 | x_1) P(x_1)$$

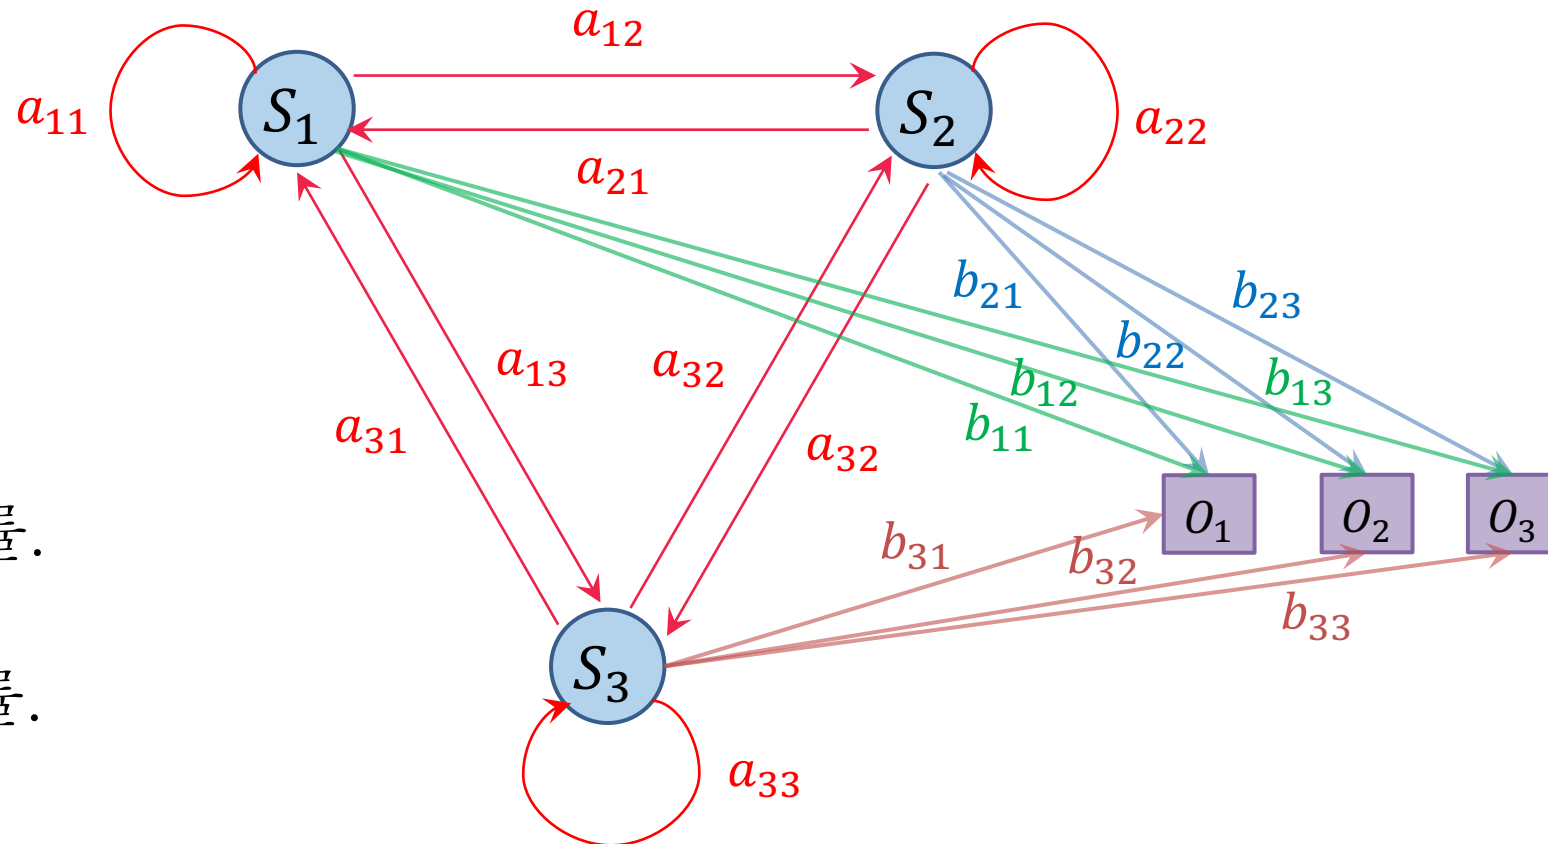
# 은닉 마르코프 모델

---

- 은닉 마르코프 모델은 다음과 같이 정의한다.
  - ⇒ 직접 관찰이 불가능한 상태  $S_1, S_2, \dots, S_N$ 가 있다.
  - ⇒ 직접 관찰이 가능한 값  $O_1, O_2, \dots, O_M$ 이 있다.  $N = M$  또는  $N \neq M$ .
  - ⇒  $S_i \rightarrow S_j$  전이에 해당하는 확률은  $a_{ij}$ 이다.
  - ⇒  $S_i$ 가  $O_j$ 로 관찰될 확률은  $b_{ij}$ 이다.
  - ⇒ 초기상태를 나타내는 확률분포  $P(x = S_i), 1 \leq i \leq N$ 가 있다.

# 은닉 마르코프 모델의 예시

- $S_1, S_2, S_3$ 은 은닉된 상태이고  $O_1, O_2, O_3$ 는 관찰 가능한 값이다.




$\Rightarrow a_{ij}$  = 전이 확률.

$\Rightarrow b_{ij}$  = 출력 확률.



# 은닉 마르코프 모델의 예시

- 영희와 철수는 멀리 떨어져서 살고 있고 안부를 전화로 물어볼 수 밖에 없다. 철수의 일과는 크게 “게임” 또는 “피트니스” 두 가지가 있는데, 무엇을 할지는 당일 날씨에 따라 결정된다.
- 영희는 철수가 살고 있는 지역의 날씨에 관해서 정확히는 모르고 “확률적” 성향만을 알고 있을 뿐이다. 영희는 철수와의 통화내용에 기반하여 그 지역의 날씨를 예측해보려고 한다.



# 은닉 마르코프 모델 : 디코딩 문제

- 은닉 상태의 시퀀스  $s_1, s_2, s_3, \dots, s_T$ 와 관찰값의 시퀀스  $o_1, o_2, o_3, \dots, o_T$ 를 전제해 본다.

은닉 상태  $s_t$ 는 관찰값  $o_t$ 를 통해서 나타난다고 생각할 수 있다.

- 그러므로 은닉 상태에 대한 정보는 다음의 조건부 **사후확률**을 통해서 알 수 있다.

$$P(s_1, s_2, s_3, \dots, s_T | o_1, o_2, o_3, \dots, o_T)$$

- 이것을 베이지 정리를 적용하여 다음 비례관계로 표현할 수 있다.

$$P(s_1, s_2, s_3, \dots, s_T | o_1, o_2, o_3, \dots, o_T) \propto P(o_1, o_2, o_3, \dots, o_T | s_1, s_2, s_3, \dots, s_T) P(s_1, s_2, s_3, \dots, s_T)$$

# 은닉 마르코프 모델 : 디코딩 문제

---

- 가장 유력한 은닉 상태 시퀀스를 찾아내고자 한다면 사후확률을 최고화 (maximize) 해야 한다.
  - ⇒ “우도함수”  $P(o_1, o_2, o_3, \dots, o_T | s_1, s_2, s_3, \dots, s_T)$ 의 최고화를 통해서 달성!
  - ⇒ 구체적으로는 “Viterbi 알고리즘”을 사용할 수 있다.

끝

---

